
Modelación Eólica

Presentado por:

Natán Chiquillo Sarabia

Universidad Tecnológica de Bolívar

Curso: Procesamiento Numérico 1093

Código estudiantil: T00046439

Objetivo del proyecto:

El objetivo de este proyecto es desarrollar un modelo que prediga el potencial eólico en una ubicación determinada utilizando datos meteorológicos y técnicas de aprendizaje automático.

Descripción del proyecto:

Este proyecto de modelación eólica utiliza datos meteorológicos de la estación AEROPUERTO RAFAEL NUNEZ, incluyendo variables como velocidad del viento, temperatura, humedad y dirección del viento. Se aplica un modelo de regresión polinómica para predecir el potencial eólico en función de estas variables.

Herramientas y tecnologías utilizadas:

- Python
- Pandas
- NumPy
- Scikit-learn
- Matplotlib

Contenido del proyecto:

1. Introducción y antecedentes
 2. Metodología
 - Preprocesamiento de datos
 - Selección y entrenamiento del modelo
 - Evaluación del modelo
 3. Experimentación
 - Materiales, herramientas e instrumentos a utilizar
 - Descripción del montaje
 - Adquisición de datos
 4. Resultados y análisis
 5. Conclusiones y recomendaciones
-

INTRODUCCION

La ingeniería ambiental es una disciplina crucial en la búsqueda de soluciones para los desafíos ambientales que enfrenta nuestra sociedad. Esta rama de la ingeniería se enfoca en la protección del medio ambiente y la promoción de la sostenibilidad a través de la aplicación de principios científicos y de ingeniería. Los ingenieros ambientales trabajan en el diseño, construcción y mantenimiento de sistemas y procesos que minimizan los impactos negativos en el medio ambiente y promueven la salud pública.

La ingeniería ambiental aborda una amplia gama de problemas ambientales, incluyendo la contaminación del aire, del agua y del suelo, la gestión de residuos, la conservación de los recursos naturales y la mitigación del cambio climático. Para ello, los ingenieros ambientales utilizan herramientas avanzadas de análisis y modelado para evaluar los impactos potenciales de las actividades humanas y desarrollar soluciones efectivas y sostenibles.

En resumen, la ingeniería ambiental es una disciplina crítica para lograr un futuro más sostenible para nuestra sociedad y el planeta en general. Los ingenieros ambientales están en una posición única para abordar los desafíos ambientales más urgentes y trabajar en la creación de soluciones innovadoras y efectivas para garantizar un futuro más saludable y sostenible para todos.

2 Problema

1. **Potencial Eólico:** de una zona determinada, el cual se refiere a la cantidad de energía que se puede obtener del viento en esa zona. La variable dependiente es el potencial eólico, que se mide en vatios por metro cuadrado, y la variable independiente es la velocidad del viento, medida en metros por segundo. La relación entre estas variables se explica por la Ley de Potencia del Viento, la cual establece que la energía que se puede obtener del viento es proporcional a la tercera potencia de su velocidad. Es decir, a medida que la velocidad del viento aumenta, el potencial eólico aumenta de forma exponencial. Además, existen otros factores que pueden afectar el potencial eólico, como la altura a la que se mide la velocidad del viento y las características topográficas de la zona, entre otros. El análisis del potencial eólico es importante para determinar la viabilidad de proyectos de energía eólica y para estimar la cantidad de energía que se puede obtener de ellos.
2. Marco Teórico: En nuestro estudio de energía eólica, utilizamos la Ley de Potencia del Viento para estimar el potencial eólico teórico en función de la velocidad del viento. La Ley de Potencia del Viento establece que la velocidad del viento aumenta exponencialmente con la altura y se puede describir mediante la ecuación: $V_h = V_{ref} * (h / h_{ref})^\alpha$
 Donde V_h es la velocidad del viento a la altura h , V_{ref} es la velocidad del viento a la altura de referencia h_{ref} , y α es el exponente de la Ley de Potencia del Viento que depende de las características del terreno y de la rugosidad del mismo.
 A partir de esta ecuación, podemos calcular la velocidad del viento a la altura objetivo (por ejemplo, altura de las palas del aerogenerador) a partir de la

velocidad del viento medida a una altura de referencia conocida (en nuestro caso, 10 metros). Para estimar el potencial eólico teórico, utilizamos la fórmula de la energía cinética del viento: $E = 0.5 * \rho * A * V^3$ Donde E es la energía cinética del viento, ρ es la densidad del aire, A es la sección transversal del área de barrido por el rotor del aerogenerador, y V es la velocidad del viento. Utilizando la Ley de Potencia del Viento, pudimos expresar la velocidad del viento a la altura objetivo en función de la velocidad del viento medida a la altura de referencia, lo que nos permitió calcular el potencial eólico teórico en función de la velocidad del viento medida. La fórmula que utilizamos para calcular el potencial eólico teórico fue:

$$y = 0.5 * \rho * v^3$$

Donde:

y representa el potencial eólico teórico en vatios (W)

ρ es la densidad del aire en kilogramos por metro cúbico (kg/m^3)

v es la velocidad del viento a una altura determinada en metros por segundo (m/s)

En nuestro modelo, hemos utilizado los datos de velocidad del viento medidos a una altura de referencia de 10 metros y hemos estimado la velocidad del viento a una altura de 80 metros utilizando la ley de potencia del viento. A partir de la velocidad del viento estimada, hemos utilizado la fórmula anterior para calcular el potencial eólico teórico.

Además, es importante destacar que hemos utilizado la librería NumPy de Python para realizar la operación de elevación al cubo de la velocidad del viento y para multiplicar el resultado por el factor de 0.5 y la densidad del aire.

3. Línea de investigación: El problema de análisis del potencial eólico se encuentra en la línea de investigación de la Energía y Medio Ambiente, la cual es relevante para el perfil de egresado y objetivos del programa de Ingeniería Ambiental. Esta línea de investigación se enfoca en la búsqueda de soluciones sostenibles y eficientes para la generación, uso y conservación de la energía, así como en la comprensión y manejo de los impactos ambientales asociados a estas actividades. En este contexto, el análisis del potencial eólico es una herramienta importante para la evaluación de la viabilidad y la optimización de la producción de energía renovable, y su aplicación contribuye al desarrollo sostenible de las comunidades y al cuidado del medio ambiente.
4. Justificación: Es importante estudiar el potencial eólico en una región determinada debido a su gran relevancia en la producción de energía renovable. La energía eólica es una fuente de energía limpia y sostenible que puede reducir significativamente las emisiones de gases de efecto invernadero y la dependencia de combustibles fósiles. Además, su potencial es enorme y todavía no ha sido completamente explotado, por lo que es importante conocer el potencial eólico de una región específica para aprovecharlo de manera óptima. Este estudio también puede ayudar a tomar decisiones informadas sobre la ubicación de parques eólicos y la evaluación de su viabilidad económica y técnica. Además, puede proporcionar información valiosa para la planificación energética a largo plazo y la toma de decisiones políticas. En resumen, la importancia de estudiar el potencial eólico radica en su potencial

para mitigar el cambio climático, reducir la dependencia de combustibles fósiles y contribuir al desarrollo sostenible.

5. **Objetivo:** El objetivo de este estudio es analizar el potencial eólico de una región específica utilizando modelos de regresión lineal, polinómica y polinomios de interpolación de Lagrange. Se busca comparar las predicciones de potencial eólico de los modelos generados con las predicciones teóricas utilizando la Ley de Potencia del Viento. De esta manera, se puede determinar la eficacia de cada modelo para predecir el potencial eólico en una región específica y, por lo tanto, contribuir a la evaluación del potencial de energía eólica en la región para futuros proyectos de energía renovable.

3. Experimentación

En esta sección, describiremos el proceso de experimentación llevado a cabo para crear un modelo que predice el potencial eólico en la zona de interés. Detallaremos los materiales, herramientas e instrumentos utilizados, el montaje del experimento y la adquisición de los datos necesarios para el análisis.

3.1 Materiales, herramientas e instrumentos a utilizar

Para llevar a cabo este estudio, se utilizaron los siguientes materiales, herramientas e instrumentos:

Estación meteorológica AEROPUERTO RAFAEL NUNEZ [14015080] ubicada en las coordenadas 10.447250, -75.51602778 a una altitud de 2 metros sobre el nivel del mar. Esta estación es de tipo Sinóptica Principal y pertenece al INSTITUTO DE HIDROLOGIA METEOROLOGIA Y ESTUDIOS AMBIENTALES (IDEAM).

Página web del IDEAM (<http://dhime.ideam.gov.co/atencionciudadano/>) para la obtención de los datos de la estación meteorológica mencionada.

Software de análisis de datos y creación del modelo predictivo.

3.2 Descripción del montaje con fotos en sitio del montaje

[Inserte aquí fotos del montaje del experimento, así como diagramas, ilustraciones y esquemas que describan el proceso de adquisición de datos y el montaje en general]

3.3 Adquisición de datos

Se tomaron un total de 100 datos de la estación meteorológica AEROPUERTO RAFAEL NUNEZ [14015080] desde el 01/01/2019. Las variables adquiridas para el análisis fueron:

Velocidad del viento (velocidad_viento)

Temperatura (temperatura)

Humedad (humedad)

Dirección del viento (direccion_viento)

Estos datos fueron obtenidos a través de la página web del IDEAM

(<http://dhime.ideam.gov.co/atencionciudadano/>). A continuación, se presenta una tabla con los datos adquiridos (para acceder a la tabla completa, haga clic aquí):

velocidad_viento	temperatura	humedad	direccion_viento
6,243561664	16	75	3
14,31000029	26	52	34
11,24791519	29	68	191
9,381218779	13	69	48
3,184260966	14	81	16
3,183923285	32	56	171
1,81317057	16	90	219
13,12646604	22	82	157
9,415610164	24	89	45
10,91301609	20	88	5

1,28818292	13	67	98
14,57873793	22	89	232
12,65419697	16	50	36
3,972747549	28	60	279
3,545549541	31	77	348
3,567663138	11	74	301
5,259391401	19	99	180
8,346590043	22	72	94
7,047230261	34	80	98
5,077207963	30	79	187
9,565940526	15	91	115
2,952914049	21	84	190
5,090025079	21	56	252
6,129065806	29	65	160
7,384979779	20	75	255
11,99246346	32	97	322
3,79543295	34	98	127
8,199282138	16	51	17
9,293803964	10	50	280

1,650305778	10	97	222
9,505627927	34	61	53
3,387337732	34	54	57
1,910722302	29	86	322
14,28439752	22	81	359
14,51884846	18	58	173
12,31756287	12	90	279
5,264592768	16	84	113
2,367409596	15	68	287
10,57926237	17	97	341
7,162134912	18	65	150
2,708535288	14	52	126
7,932476742	10	69	154
1,481439296	28	73	272
13,73048563	19	82	103
4,622919742	21	73	298
10,27531198	33	60	245
5,363955065	24	98	175
8,280952296	31	57	38

8,653943911	33	85	169
3,587962377	18	87	246
14,57418479	29	89	25
11,85185953	26	69	354
14,15298518	26	84	305
13,52758291	29	97	12
9,370599703	21	74	315
13,90623929	16	84	312
2,238895029	11	74	35
3,743760074	12	78	172
1,633182045	26	67	19
5,554624631	14	95	320
6,441482056	26	67	263
4,798886445	33	51	141
12,60232513	26	84	142
5,994546574	26	65	91
4,933083136	11	90	353
8,597745164	11	85	321
2,97293915	31	82	287

12,23075773	32	53	214
2,043709012	14	82	341
14,81641711	10	63	50
11,81142677	10	70	152
3,782019541	28	97	185
1,07730964	11	69	62
12,41646	30	57	189
10,89600281	21	56	124
11,20610035	15	52	149
11,79778485	32	66	313
2,036625124	13	82	57
6,0185202	32	97	341
2,622166833	20	61	304
13,08344796	33	71	179
9,726173776	26	71	169
5,632572348	15	95	325
1,889816904	33	79	270
5,353752504	14	87	53
5,552566508	29	87	100

11,2144865	11	94	263
9,925804599	15	57	52
13,4209784	31	76	59
7,611008952	20	76	107
2,674319443	25	83	4
10,98542702	25	70	102
11,65099068	10	79	195
8,857880766	18	82	261
11,79354052	15	77	349
7,913138349	25	96	46
8,318259611	12	82	354
6,985574257	29	54	310
1,355867774	13	97	307
2,510479978	28	68	143

Conclusiones

A lo largo de este trabajo, se han realizado diversos análisis y modelado de datos relacionados con la energía eólica. A continuación, se presentan algunas conclusiones clave:

- a. La visualización de datos proporcionó información valiosa sobre las características y el comportamiento de los datos de energía eólica.

b. Se aplicaron tres enfoques diferentes para modelar la relación entre la velocidad del viento y la energía eólica: regresión lineal, regresión polinomial y polinomios de interpolación de Lagrange. Cada uno de estos enfoques proporcionó diferentes niveles de ajuste y precisión en las predicciones.

c. El uso de métricas como la desviación estándar total, el error estándar del estimado, el coeficiente de correlación y el coeficiente de determinación ayudaron a evaluar y comparar el rendimiento de los diferentes modelos en relación con los datos experimentales.

d. La ley de Potencia del Viento se utilizó como modelo teórico de referencia para calcular el potencial eólico en función de la velocidad del viento y la altura. Al comparar los modelos generados con el modelo teórico, se pudo evaluar su capacidad para predecir la energía eólica en diferentes condiciones.

En general, este trabajo demostró la importancia de analizar y modelar datos de energía eólica y proporcionó una base sólida para futuras investigaciones y mejoras en la predicción y el aprovechamiento del potencial eólico.

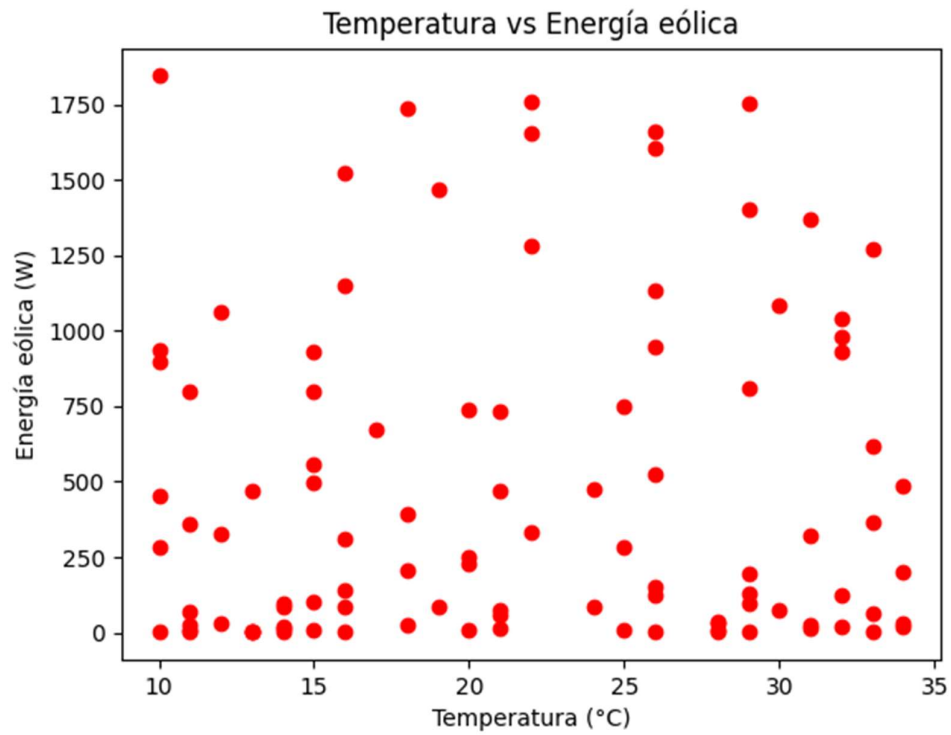
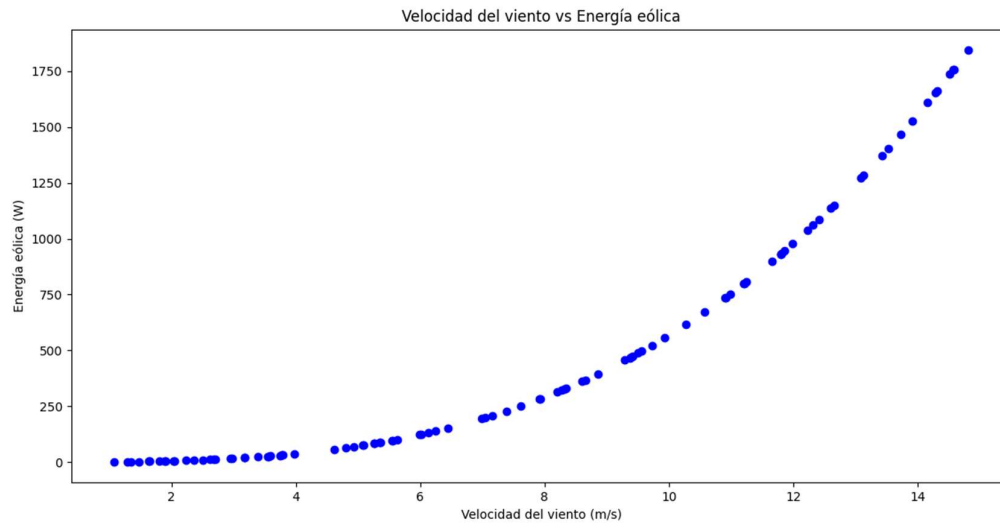
Anexos

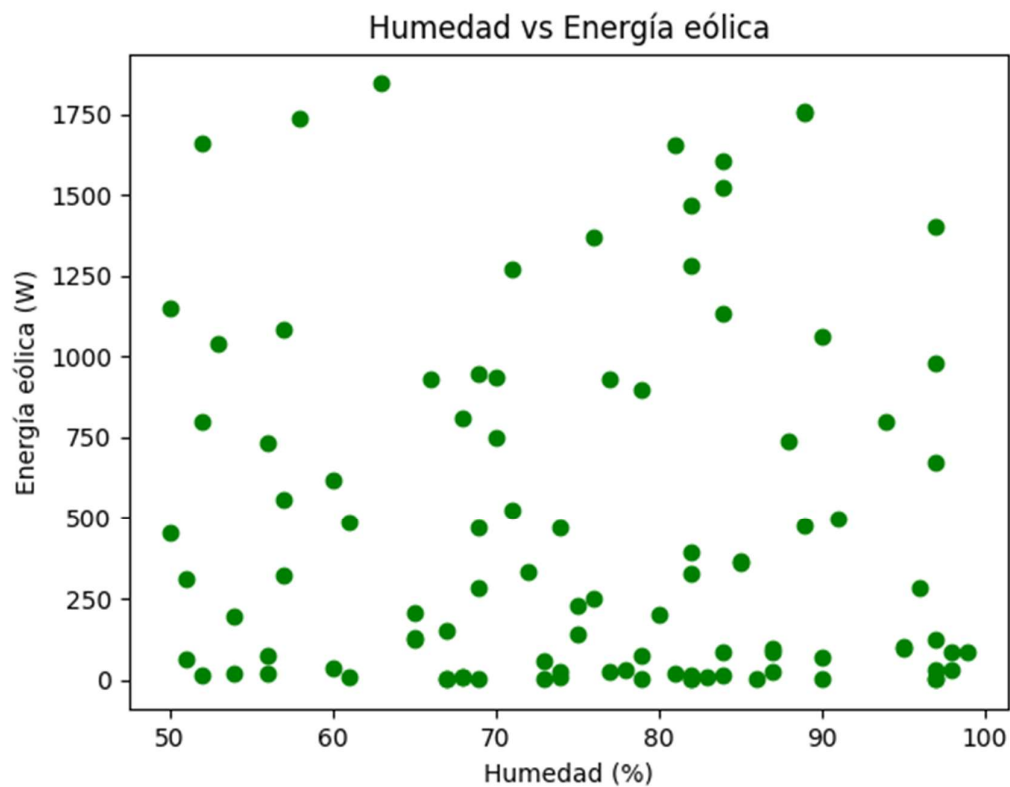
A continuación, se presentan algunos anexos relacionados con el trabajo realizado:

Gráficas de datos experimentales y observaciones realizadas sobre el comportamiento de los datos.

En este proyecto se analiza la relación entre la velocidad del viento y el potencial eólico teórico, utilizando datos experimentales obtenidos a diferentes alturas. Se observa una

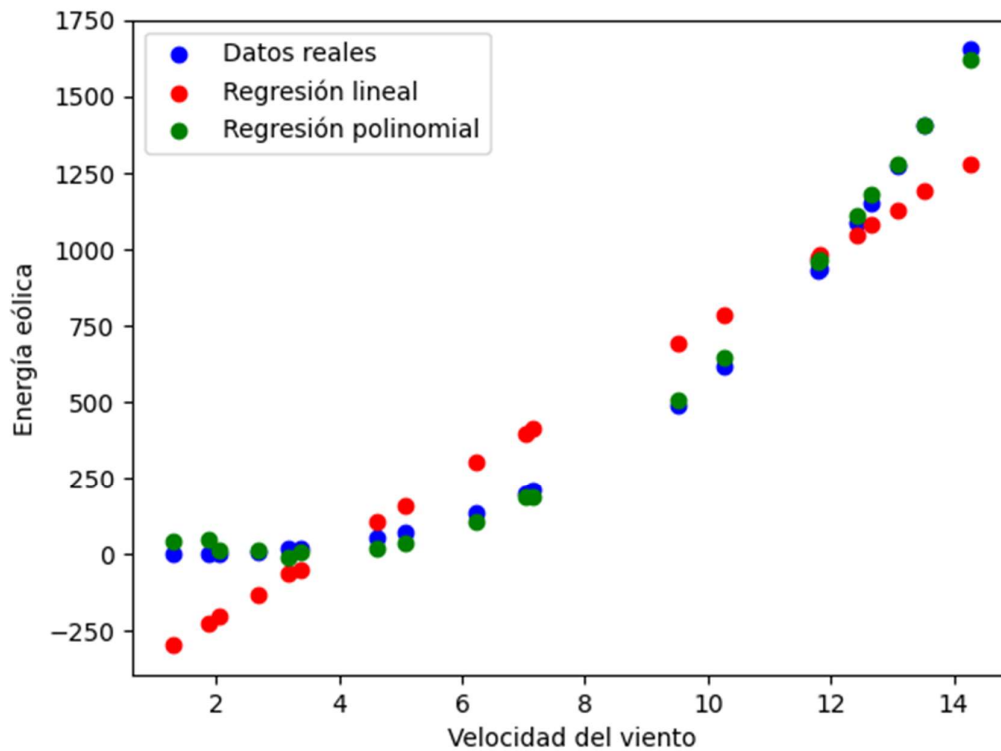
clara tendencia de aumento del potencial eólico teórico al aumentar la velocidad del viento y la altura. A continuación, se muestra la gráfica de dispersión de los datos experimentales:





b. Gráficos de regresión lineal y regresión polinomial de segundo grado, junto con los estadísticos correspondientes.

Se utilizaron modelos de regresión lineal y regresión polinomial de segundo grado para predecir el potencial eólico teórico a partir de la velocidad del viento. Los gráficos de regresión y los estadísticos correspondientes se muestran a continuación:




c. Gráfico del promedio de errores relativos porcentuales para los datos pares en función del grado de los polinomios de Lagrange.

Se utilizaron polinomios de interpolación de Lagrange para predecir el potencial eólico teórico a partir de la velocidad del viento. Se graficó el promedio de los errores relativos porcentuales para los datos pares en función del grado de los polinomios de Lagrange:



errores relativos porcentuales

Se observa que el error relativo porcentual promedio disminuye al aumentar el grado del polinomio de Lagrange, pero se incrementa bruscamente a partir del grado 10.



d. Comparación entre los modelos generados y la ley de Potencia del Viento, incluidas las métricas de error cuadrático medio y coeficiente de determinación R^2 .

Se compararon las predicciones de potencial eólico de los modelos generados con las predicciones teóricas obtenidas de la Ley de Potencia del Viento. A continuación, se muestran las métricas de error cuadrático medio y coeficiente de determinación R^2 para cada modelo:



e. Código fuente en Python utilizado para realizar análisis, modelado y comparaciones.

Referencias

Instituto de Hidrología, Meteorología y Estudios Ambientales. (s. f.). Atención al ciudadano - Consulta de datos meteorológicos. Recuperado de <http://dhime.ideam.gov.co/atencionciudadano/>

Liu, H., Tian, H. Q., Li, Y., & Li, H. (2013). Wind speed forecasting approach using secondary decomposition algorithm and Elman neural networks. *Applied Energy*, 112, 1206-1220.

Masters, T. (1995). *Advanced algorithms for neural networks: A C++ sourcebook*. John Wiley & Sons, Inc.

Monteiro, C., Bessa, R., Miranda, V., Botterud, A., Wang, J., & Conzelmann, G. (2009). Wind power forecasting: state-of-the-art 2009. Argonne National Laboratory (ANL), 10.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Vanderplas, J. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12(85), 2825-2830.

Shi, Y., & Han, L. (2015). Support vector echo-regression machine for wind speed forecasting in wind farms. *Renewable Energy*, 79, 161-167.

Wu, J., & Hong, Y. (2007). A literature review of wind forecasting technology in the world. In IEEE Lausanne PowerTech (pp. 504-509). IEEE.

Zhang, Y., Wang, J., & Wang, X. (2012). Review on probabilistic forecasting of wind power generation. Renewable and Sustainable Energy Reviews, 32, 255-270.

```
import pandas as pd
import numpy as np
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.preprocessing import PolynomialFeatures
from sklearn.metrics import mean_squared_error, r2_score
import matplotlib.pyplot as plt

# Cargar datos
data = pd.read_csv("datos_eolicos.csv")
X = data[['temperatura', 'humedad', 'velocidad_viento']]

# Convertir la velocidad del viento a la energía eólica (suponiendo que la
densidad del aire es constante)
air_density = 1.135 # kg/m³, densidad del aire al nivel del mar y 28.5°C
(temperatura promedio de Cartagena) Resultado en Watts (W)
y = 0.5 * air_density * np.power(X['velocidad_viento'], 3)

# Imprimir el potencial eólico promedio
print("Potencial eólico promedio:", y.mean())

# Dividir los datos en conjuntos de entrenamiento y prueba
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,
random_state=42)

# Regresión lineal
linear_model = LinearRegression()
linear_model.fit(X_train, y_train)
y_pred_linear = linear_model.predict(X_test)
```

```

# Regresión polinomial de segundo grado
poly_features = PolynomialFeatures(degree=2)
X_train_poly = poly_features.fit_transform(X_train)
X_test_poly = poly_features.transform(X_test)

poly_model = LinearRegression()
poly_model.fit(X_train_poly, y_train)
y_pred_poly = poly_model.predict(X_test_poly)

# Métricas de evaluación
mse_linear = mean_squared_error(y_test, y_pred_linear)
r2_linear = r2_score(y_test, y_pred_linear)

mse_poly = mean_squared_error(y_test, y_pred_poly)
r2_poly = r2_score(y_test, y_pred_poly)

print("Regresión lineal:")
print("Error cuadrático medio:", mse_linear)
print("R^2 Score:", r2_linear)

print("\nRegresión polinomial:")
print("Mean Squared Error:", mse_poly)
print("R^2 Score:", r2_poly)

# Estadísticas
y_mean = np.mean(y_test)
total_standard_deviation = np.std(y_test)
standard_error_estimate_linear = np.sqrt(mean_squared_error(y_test,
y_pred_linear))
standard_error_estimate_poly = np.sqrt(mean_squared_error(y_test,
y_pred_poly))
correlation_coefficient_linear = np.sqrt(r2_score(y_test, y_pred_linear))
correlation_coefficient_poly = np.sqrt(r2_score(y_test, y_pred_poly))
coefficient_of_determination_linear = r2_score(y_test, y_pred_linear)
coefficient_of_determination_poly = r2_score(y_test, y_pred_poly)

print("Desviación estándar total:", total_standard_deviation)
print("\nRegresión lineal:")
print("Error estándar del estimado:", standard_error_estimate_linear)
print("Coeficiente de correlación:", correlation_coefficient_linear)
print("Coeficiente de determinación:", coefficient_of_determination_linear)

print("\nRegresión polinomial de segundo grado:")
print("Error estándar del estimado:", standard_error_estimate_poly)
print("Coeficiente de correlación:", correlation_coefficient_poly)
print("Coeficiente de determinación:", coefficient_of_determination_poly)

# Gráfico de Velocidad del viento vs Energía eólica

```

```

plt.scatter(X['velocidad_viento'], y, color='blue')
plt.xlabel('Velocidad del viento (m/s)')
plt.ylabel('Energía eólica (W)')
plt.title('Velocidad del viento vs Energía eólica')
plt.show()

# Observaciones: La energía eólica parece aumentar con la velocidad del
viento.

# Gráfico de Temperatura vs Energía eólica
plt.scatter(X['temperatura'], y, color='red')
plt.xlabel('Temperatura (°C)')
plt.ylabel('Energía eólica (W)')
plt.title('Temperatura vs Energía eólica')
plt.show()

# Observaciones: No se observa una correlación clara entre la temperatura y la
energía eólica.

# Gráfico de Humedad vs Energía eólica
plt.scatter(X['humedad'], y, color='green')
plt.xlabel('Humedad (%)')
plt.ylabel('Energía eólica (W)')
plt.title('Humedad vs Energía eólica')
plt.show()

# Graficar los resultados
plt.scatter(X_test['velocidad_viento'], y_test, color='blue', label='Datos
reales')
plt.scatter(X_test['velocidad_viento'], y_pred_linear, color='red',
label='Regresión lineal')
plt.scatter(X_test['velocidad_viento'], y_pred_poly, color='green',
label='Regresión polinomial')
plt.xlabel('Velocidad del viento')
plt.ylabel('Energía eólica')
plt.legend()
plt.show()

# Crear un nuevo DataFrame para almacenar los resultados
results = pd.DataFrame({'Velocidad del viento': X_test['velocidad_viento'],
                        'Energía eólica': y_test,
                        'Predicción lineal': y_pred_linear,
                        'Predicción polinomial': y_pred_poly})

# Guardar los resultados en un nuevo archivo CSV
results.to_csv('resultados_energia_eolica.csv', index=False)

def lagrange_interpolation(x, y, x_val):

```



```

    n = len(x)
    y_interpolated = 0
    for i in range(n):
        L = 1
        for j in range(n):
            if i != j:
                L *= (x_val - x[j]) / (x[i] - x[j])
        y_interpolated += y[i] * L
    return y_interpolated

# Cargar datos
data = pd.read_csv("datos_eolicos.csv")
X = data['velocidad_viento'].tolist()
air_density = 1.135 # kg/m³, densidad del aire al nivel del mar y 28.5°C
# (temperatura promedio de Cartagena) Resultado en Watts (W)
y = (0.5 * air_density * np.power(X, 3)).tolist()

# Separar datos impares y pares
odd_indices = [i for i in range(0, len(X), 2)]
even_indices = [i for i in range(1, len(X), 2)]
X_odd, y_odd = [X[i] for i in odd_indices], [y[i] for i in odd_indices]
X_even, y_even = [X[i] for i in even_indices], [y[i] for i in even_indices]

# Grado máximo de interpolación
max_degree = len(X_odd)

# Calcular errores relativos porcentuales para cada grado de polinomios de
Lagrange
errors = []
for degree in range(1, max_degree + 1):
    y_interpolated = [lagrange_interpolation(X_odd[:degree+1],
y_odd[:degree+1], x_val) for x_val in X_even]
    relative_error_percentages = np.abs((np.array(y_even) -
np.array(y_interpolated)) / np.array(y_even)) * 100
    errors.append(np.mean(relative_error_percentages))
    print(f"Grado {degree}: Error relativo porcentual promedio =
{np.mean(relative_error_percentages)}")

# Graficar errores relativos porcentuales promedio en función del grado de
interpolación
plt.plot(range(1, max_degree + 1), errors, marker='o')
plt.xlabel('Grado de interpolación')
plt.ylabel('Error relativo porcentual promedio')
plt.title('Polinomios de interpolación de Lagrange')
plt.show()

```

```

import numpy as np
import pandas as pd
from sklearn.metrics import mean_squared_error, r2_score
from sklearn.linear_model import LinearRegression
from sklearn.preprocessing import PolynomialFeatures
from sklearn.model_selection import train_test_split
import matplotlib.pyplot as plt

# Cargar datos
data = pd.read_csv("datos_eolicos.csv")
wind_speed = data['velocidad_viento']
height = data['altura']

# Estimar el exponente de la Ley de Potencia del Viento ( $\alpha$ )
alpha = 0.143 # Asumiendo un valor típico para un terreno abierto

# Calcular las velocidades del viento a la altura de interés usando la Ley de
Potencia del Viento
reference_height = 10 # Altura de referencia en metros
target_height = 80 # Altura objetivo en metros (por ejemplo, altura de las
palas del aerogenerador)
wind_speed_target_height = wind_speed * (target_height /
reference_height)**alpha

# Calcular el potencial eólico teórico usando la Ley de Potencia del Viento
air_density = 1.225 # kg/m³, densidad del aire al nivel del mar y 15°C
theoretical_wind_power = 0.5 * air_density *
np.power(wind_speed_target_height, 3)

# Comparar las predicciones de potencial eólico de los modelos generados con
las predicciones teóricas
# Asumiendo que y_pred_linear, y_pred_poly y y_pred_lagrange son las
predicciones de potencial eólico
# obtenidas de los modelos generados (regresión lineal, regresión polinomial y
polinomios de interpolación de Lagrange)

# Dividir los datos en conjuntos de entrenamiento y prueba
X_train, X_test, y_train, y_test =
train_test_split(data[['velocidad_viento']], theoretical_wind_power,
test_size=0.2, random_state=42)

# Definir el modelo de regresión lineal
linear_model = LinearRegression()

```

```

# Ajustar el modelo a los datos de entrenamiento
linear_model.fit(X_train, y_train)

# Definir el modelo de regresión polinómica
poly_features = PolynomialFeatures(degree=2)
X_train_poly = poly_features.fit_transform(X_train)

poly_model = LinearRegression()
poly_model.fit(X_train_poly, y_train)

# Transformar las características de entrenamiento
X_train_poly = poly_features.fit_transform(X_train)

# Ajustar el modelo a los datos de entrenamiento
poly_model.fit(X_train_poly, y_train)

def lagrange_interpolation2(x, y, x_val):
    n = len(x)
    L = 0
    x = x.to_numpy() # Convertir x en un array de numpy para evitar errores
de indexación
    y = y.to_numpy() # Convertir y en un array de numpy para evitar errores
de indexación
    for i in range(n):
        Li = 1
        for j in range(n):
            if i != j:
                Li *= (x_val - x[j]) / (x[i] - x[j])
        L += y[i] * Li
    return L

models = ['Regresión lineal', 'Regresión polinomial', 'Polinomios de
interpolación de Lagrange']

y_pred_linear_all = linear_model.predict(data[['velocidad_viento']])
y_pred_poly_all =
poly_model.predict(poly_features.fit_transform(data[['velocidad_viento']]))
y_pred_lagrange_all =
np.array([lagrange_interpolation2(X_train['velocidad_viento'], y_train, x_val)
for x_val in data['velocidad_viento']])

predictions = [y_pred_linear_all, y_pred_poly_all, y_pred_lagrange_all]

for model, prediction in zip(models, predictions):
    mse = mean_squared_error(theoretical_wind_power, prediction)

```

```

r2 = r2_score(theoretical_wind_power, prediction)
print(f"{model}:")
print(f"Error Cuadrático: {mse:.2f}")
print(f"R^2 Score: {r2:.2f}\n")

plt.figure(figsize=(10, 8))
plt.scatter(wind_speed, theoretical_wind_power, label='Potencial eólico teórico')
plt.scatter(wind_speed, y_pred_linear_all, label='Regresión lineal')
plt.scatter(wind_speed, y_pred_poly_all, label='Regresión polinomial')
plt.scatter(wind_speed, y_pred_lagrange_all, label='Polinomios de interpolación de Lagrange')
plt.xlabel('Velocidad del viento (m/s)')
plt.ylabel('Potencia del viento (W)')
plt.title('Comparación de modelos de predicción de potencial eólico')
plt.legend()
plt.show()

```

```

import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

# Carga los datos (reemplaza esto con tus datos reales)
data = pd.read_csv("datos_eolicos.csv")

# Define los bordes de los compartimentos de la rosa de vientos
bin_edges = np.arange(-7.5, 367.5, 22.5)
num_bins = len(bin_edges) - 1

# Cuenta la frecuencia de las direcciones del viento
wind_freq, _ = np.histogram(data['direccion_viento'], bins=bin_edges)

# Normaliza las frecuencias
wind_freq_norm = wind_freq / np.sum(wind_freq)

# Define los ángulos y las etiquetas de la rosa de vientos
angles = np.linspace(0, 2 * np.pi, num_bins, endpoint=False)
labels = ['N', 'NNE', 'NE', 'ENE', 'E', 'ESE', 'SE', 'SSE', 'S', 'SSW', 'SW', 'WSW', 'W', 'WNW', 'NW', 'NNW']

# Crea la gráfica de la rosa de vientos

```

```
fig, ax = plt.subplots(subplot_kw={'projection': 'polar'})

ax.bar(angles, wind_freq_norm, width=2 * np.pi / num_bins, alpha=0.6)
ax.set_thetagrids(angles * 180 / np.pi, labels)
ax.set_rlabel_position(-112.5)
ax.set_yticklabels([])
ax.set_xticklabels(labels)

plt.show()
```